

Alinhamento Interpretável de Mecanismos de Atenção com Racionalizações Morais para Detecção de Discurso de Ódio

Francielle Vargas

Professora Assistente
Iniciativa em Dados e Inteligência Artificial
Universidade do Chile



Discurso de Ódio no Brasil




Figure: Denúncias de discurso de ódio durante o período de 2017–2018 (safernet 2018).

Definindo Discurso Ódio

Definindo Discurso de Ódio, Linguagem Ofensiva e Toxicidade.




Figure: Relatório da Organização das Nações Unidas (ONU), 2024.

Detectar Discurso de Ódio Vai Além de Palavras Ofensivas

- ▶ O problema dela é que a tetinha secou
- ▶ A atoa lambedora saco de miliciano....
- ▶ Os gados gostam de pagar para tirar férias
- ▶ Isso aqui vai virar uma venezuela
- ▶ COMUNISTA SAFADA, MALPARIDA, MAMAGUEVA, DESGRAÇADA, COÑO É TU MADRE
- ▶ Quem tem pena é galinha, mas ela é uma VACA LOUCA
- ▶ Mande essa Bachelet plantar batata no asfalto. Puta que pariu até o tamborete de bordel se acha no direito de falar do Brasil
- ▶ Pepa Pig é igual as mulheres das esquinas de rodoviária
- ▶ BACHELETA DA TRETA E MUTRETA CHILENA..CANALHA SAPATONA..

¹**Warning:** This presentation contains offensive content.

- ▶ O discurso de ódio é um fenômeno **fortemente dependente do contexto**, incluindo fatores culturais, históricos e sociais [6].
- ▶ O discurso de ódio **não pode ser identificado apenas por palavras ou expressões isoladas**.
 - ▶ *Imigrantes devem ser expulsos do país*
- ▶ Modelos de aprendizado de máquina **podem reproduzir e amplificar vieses sociais presentes nos dados de treinamento** [2]

Vieses na Detecção de Discurso de Ódio

Modelos para detecção de discurso de ódio tendem a apresentar **overfitting em relação a termos específicos** presentes nos dados de treinamento (por exemplo, “gay”, “negros” ou “mulheres”), o que pode levar a **falsos positivos**, à introdução de vieses e à redução do desempenho e da robustez dos modelos [1].


Documentos	Classe Prevista
Para muitos <u>africanos</u> , o tipo mais ameaçador de ódio étnico é o de <u>negros</u> contra <u>negros</u> .	discurso de ódio
Há uma grande discrepância entre <u>brancos</u> e <u>negros</u> na África do Sul. Isso é . . . [porque] <u>negros</u> sempre serão a raça mais atrasada do mundo - Usuário anônimo.	discurso de ódio

Table: Dois documentos classificados como discurso de ódio por um classificador BERT ajustado. Os identificadores de grupos estão sublinhados [4].

Como projetar modelos de detecção de discurso de ódio capazes de **reduzir a dependência de correlações lexicais espúrias, incorporar fatores contextuais e socioculturais, e mitigar a transferência de vieses sociais dos dados de treinamento** para as previsões do modelo?

Moderação de Discurso de Ódio com Racionalizações Morais

- ▶ **NN:** Não-Moralidade (*Non-Morality*)
- ▶ **HN:** Cuidado/Dano (*Harm/Care*)
- ▶ **FN:** Justiça/Trapaça (*Fairness/Cheating*)
- ▶ **PN:** Pureza/Degradação (*Purity/Degradation*)
- ▶ **AN:** Autoridade/Subversão (*Authority/Subversion*)
- ▶ **LN:** Lealdade/Traição (*Loyalty/Betrayal*)



- ▶ **Interpretabilidade de Modelos de Linguagem** [5]: busca compreender as representações internas e o comportamento dos modelos.
- ▶ **Alinhamento da IA** [3]: visa garantir que o comportamento dos modelos esteja alinhado aos valores humanos (e.g. valores moraes, normas sociais, etc.), e aos objetivos pretendidos.

Inovação: *As técnicas atuais de alinhamento frequentemente operam sem uma compreensão do comportamento dos modelos, enquanto os métodos de interpretabilidade raramente são utilizados para orientar diretamente estratégias de alinhamento.*

Mecanismo de Atenção Supervisionado por Racionalizações Morais

- **Alinhamento Interpretável da Atenção** (*Interpretable Attention Alignment*): atenção neural supervisionada por rationales humanos de moralidade através de uma **regularização indutiva normativa** (*normative inductive regularization*), que incentiva o modelo a fundamentar suas decisões guiada por normas ou conhecimento normativos, como evidências morais humanas.




Figure: Supervised Moral Rationale Attention

O que é o SMRA (Supervised Moral Rational Attention)?

Alinhamento Interpretável de Mecanismos de Atenção com Racionalizações Morais é um framework de **regularização indutiva baseada em conhecimento humano**. O modelo aprende simultaneamente a classificar e a alinhar sua atenção neural com as justificativas morais (*moral rationales*) de anotado por especialistas humanos.

Dois objetivos de treino:

1. Classificação

Otimiza a acurácia na detecção de discurso de ódio e na identificação de fundamentos morais (ℓ_{CE}).

2. Explicação

Força o modelo a “olhar” para as mesmas palavras relevantes que os humanos destacaram (ℓ_{MSE}).

Formulação do Problema

Classificação binária de discurso de ódio e a classificação multirrótulo de sentimento moral, guiadas por um *mecanismo de regularização*.

Definição de Entrada e Espaço de Rótulos: Seja $x = (w_1, w_2, \dots, w_L)$ uma sequência de entrada tokenizada de comprimento L . O problema é modelado como uma tarefa de classificação onde o espaço de categorias morais é definido pelo conjunto de MFT:

$$\mathcal{Y} = \{\text{NN}, \text{HN}, \text{FN}, \text{PN}, \text{AN}, \text{LN}\} \quad (1)$$

Onde o número de categorias é $C = |\mathcal{Y}| = 6$, correspondendo respectivamente a:

- ▶ **NN:** Não-Moralidade (*Non-Morality*)
- ▶ **HN:** Cuidado/Dano (*Harm/Care*)
- ▶ **FN:** Justiça/Trapaça (*Fairness/Cheating*)
- ▶ **PN:** Pureza/Degradação (*Purity/Degradation*)
- ▶ **AN:** Autoridade/Subversão (*Authority/Subversion*)
- ▶ **LN:** Lealdade/Traição (*Loyalty/Betrayal*)

Dessa forma, para cada sequência x , o vetor de alvos associado é denotado por $y \in \{0, 1\}^C$.

O pipeline inicial processa o texto através de um codificador Transformer bidirecional (ex: BERTimbau ou mBERT):

- ▶ **Tokenização e Codificação:** O texto x é mapeado em L tokens, gerando representações contextualizadas $\mathbf{h}_i$ para cada palavra e para o token especial $\mathbf{h}_{[\text{CLS}]}$.
- ▶ **Função de Perda (ℓ_{CE}):** Calcula-se o erro de classificação usando a **Cross-Entropy** sobre o espaço de categorias morais ($C = 6$) e a classificação binária de discurso de ódio ($C = 2$).

Alinhamento Interpretável de Mecanismos de Atenção com Racionalizações

Em vez de tratar a atenção como um subproduto estocástico, o SMRA a supervisiona diretamente:

- ▶ **Extração da Atenção do Modelo (a):** Isola-se o vetor de pesos de atenção do token [CLS] em relação a todos os outros tokens ($w_1, \dots, w_L$) obtido na **última camada do encoder**.
- ▶ **Máscara de Racionais (r):** Os *spans* textuais anotados por humanos no dataset *HateBRMoralXplain* são convertidos em um vetor binário alinhado, onde:

$$r_i = \begin{cases} 1, & \text{se o token } w_i \text{ é semanticamente saliente (} \textit{moral rationales} \text{)} \\ 0, & \text{caso contrário} \end{cases}$$

- ▶ **Função de Perda Auxiliar (ℓ_{MSE}):** Mede-se a divergência via Erro Quadrático Médio:

$$\ell_{\text{MSE}} = \frac{1}{L} \sum_{i=1}^L (a_i - r_i)^2$$

Durante o *backpropagation*, as duas tarefas são unificadas em uma única função de perda multiobjetivo:

$$\ell_{\text{total}} = \ell_{\text{CE}} + \alpha \cdot \ell_{\text{MSE}} \quad (2)$$

Parâmetros de Controle

- ▶ **α (Hiperparâmetro de Peso):** Definido experimentalmente como 0.001. Garante que o gradiente da explicação guie a geometria de atenção do Transformer sem prejudicar a convergência da classificação.
- ▶ **Aplicação Condicional:** O termo ℓ_{MSE} é dinamicamente mascarado. Ele só é calculado se a instância possuir conteúdo moral explícito e houver raciais disponíveis ($\sum_i r_i > 0 \wedge y \neq \text{NN}$).

Resultados

Model	Classification			Plausibility			Faithfulness		Fairness/Bias (AUC)		
	Acc.↑	Macro F1↑	AUROC↑	IOU F1↑	Token F1↑	AUPRC↑	Comp.↑	Suff.↓	Sub.↑	BPSN.↑	BNSP.↑
Hate classification											
mBERT-base	0.5343	0.5013	0.5640	0.8186	0.8832	0.8829	0.0113	0.1381	0.4653	0.5234	0.5341
mBERT-smra	0.5414	0.5037	0.5588	0.8366	0.8953	0.9163	0.0235	0.1376	0.4236	0.4529	0.5343
BERTimbau-base	0.9029	0.9028	0.9651	0.7612	0.8455	0.8307	0.1733	0.0657	0.9378	0.9721	0.9365
BERTimbau-smra	0.9114	0.9110	0.9648	0.8355	0.8958	0.9273	0.1530	0.0426	0.9299	0.9694	0.9197
Moral classification											
mBERT-base	0.2700	0.1966	0.5158	0.7270	0.9659	0.9712	0.6422	0.0848	0.4112	0.5836	0.5316
mBERT-smra	0.2114	0.1698	0.5539	0.7402	0.9659	0.9712	0.6301	0.0995	0.5362	0.5912	0.6123
BERTimbau-base	0.7200	0.7570	0.9250	0.2350	0.7250	0.9150	0.8452	0.0549	0.9139	0.9604	0.9650
BERTimbau-smra	0.7230	0.7720	0.9270	0.2396	0.9660	0.9710	0.9062	0.0562	0.9212	0.9503	0.9491

Table: Results across transformer-based models for hate speech and moral sentiment classification in Portuguese using mBERT and BERTimbau under two evaluation settings: binary classification (LABELS = [Hate, Non-Hate]) and multi-label classification (LABELS = ['NN', 'HN', 'FN', 'PN', 'AN', 'LN'], where NN = Non-Morality, HN = Harm/Care, FN = Fairness/Cheating, and PN = Purity/Degradation). The *base* variant refers to models without supervised attention, while *smra* denotes our supervised attention approach guided by moral rationales.

Model and Prompt	Hate Speech (F1)		Morality (F1)	
	pt	en	pt	en
Gpt4o-m hate only	0.864	0.739	–	–
Gpt4o-m hate w/ definition	0.893	0.797	–	–
Gpt4o-m hate w/ context	0.822	0.708	–	–
Gpt4o-m hate moral	0.870	0.745	0.369	0.378
Gpt4o-m hate moral w/ definition	0.897	0.790	0.366	0.396
Gpt4o-m hate moral w/ context	0.893	0.805	0.359	0.374
Gpt4o-m moral	–	–	0.351	0.334
Gpt4o-m moral w/ definition	–	–	0.346	0.358
Gpt4o-m moral w/ context	–	–	0.308	0.295
Llama70B hate only	0.822	0.740	–	–
Llama70B hate w/ definition	0.901	0.871	–	–
Llama70B hate w/ context	0.818	0.732	–	–
Llama70B hate moral	0.826	0.725	0.370	0.360
Llama70B hate moral w/ definition	0.893	0.835	0.379	0.393
Llama70B hate moral w/ context	0.807	0.712	0.383	0.341
Llama70B moral	–	–	0.270	0.265
Llama70B moral w/ definition	–	–	0.318	0.306
Llama70B moral w/ context	–	–	0.245	0.219

Figure: F1 scores for hate speech detection and moral sentiment classification for datasets in Portuguese and their English translations. Results for GPT-4o-mini and LLaMA-70B under different prompting strategies.

Os resultados experimentais mostram que o SMRA melhora a fidelidade e a plausibilidade das explicações, ao mesmo tempo em que traz uma leve melhora no desempenho preditivo. A equidade (fairness) permanece estável, sugerindo que melhorias na qualidade das explicações não introduzem trade-offs significativos de viés. De modo geral, nossos achados destacam a **importância de integrar raciocínio moral e sensível ao contexto na detecção de discurso de ódio, contribuindo para abordagens mais interpretáveis e culturalmente conscientes.**

Self-Explaining Hate Speech Detection with Moral Rationales (ACL 2026)³

Self-Explaining Hate Speech Detection with Moral Rationales

Francielle Vargas
University of Chile

Jackson Trager
University of Southern California

Diego Alves
Saarland University

Matteo Guida
University of Melbourne

Surendrabikram Thapa
Virginia Tech

Berk Atil
Pennsylvania State University

Daryna Dementieva
Technical University of Munich

Andrew Smart
Google Research

Ameeta Agrawal
Portland State University

Abstract

Existing hate speech detection models are often opaque and rely on surface-level lexical cues, which makes them vulnerable to spurious correlations and limits robustness, interpretability and cultural contextualization. We propose Supervised Moral Rationale Attention (SMRA)¹, the first self-explaining hate speech detection framework to incorporate moral rationales as direct supervision for attention alignment. Based on Moral Foundations Theory, SMRA aligns token-level attention with expert-annotated moral rationales, guiding models to attend to morally salient spans. Unlike prior rationale-supervised or post-hoc approaches, SMRA integrates moral rationale supervision directly into the training objective, producing inherently interpretable and contextualized ex-




Figure 1: Supervised Moral Rationale Attention (SMRA) for Self-Explaining Hate Speech Detection.

³Francielle Vargas, Jackson Trager, Diego Alves, Matteo Guida, Surendrabikram Thapa, Berk Atil, Daryna Dementieva, Andrew Smart, Ameeta Agrawal. *Findings of the Association for Computational Linguistics: ACL 2026*. pp. 1–18. San Diego, USA.

-  Giuseppe Attanasio, Debora Nozza, Dirk Hovy, and Elena Baralis.
Entropy-based attention regularization frees unintended bias mitigation from lists.
In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 1105–1119, Dublin, Ireland, May 2022. Association for Computational Linguistics.
-  Aida Davani, Mark Díaz, Dylan Baker, and Vinodkumar Prabhakaran.
D3CODE: Disentangling disagreements in data across cultures on offensiveness detection and evaluation.
In Yaser Al-Onaizan, Mohit Bansal, and Yun-Nung Chen, editors, *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 18511–18526, Miami, Florida, USA, November 2024. Association for Computational Linguistics.

References

-  Jiaming Ji, Tianyi Qiu, Boyuan Chen, Jiayi Zhou, Borong Zhang, Donghai Hong, Hantao Lou, Kaile Wang, Yawen Duan, Zhonghao He, Lukas Vierling, Zhaowei Zhang, Fanzhi Zeng, Juntao Dai, Xuehai Pan, Hua Xu, Aidan O’Gara, Kwan Ng, Brian Tse, Jie Fu, Stephen Mcaleer, Yanfeng Wang, Mingchuan Yang, Yunhuai Liu, Yizhou Wang, Song-Chun Zhu, Yike Guo, Yaodong Yang, and Wen Gao.
Ai alignment: A contemporary survey.
ACM Computing Surveys, 58(5), 2025.
-  Brendan Kennedy, Xisen Jin, Aida Mostafazadeh Davani, Morteza Dehghani, and Xiang Ren.
Contextualizing hate speech classifiers with post-hoc explanation.

In Dan Jurafsky, Joyce Chai, Natalie Schluter, and Joel Tetreault, editors, *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 5435–5442, Held Online, 2020.

-  Lucas Resck, Isabelle Augenstein, and Anna Korhonen.
Explainability and interpretability of multilingual large language models: A survey.
In Christos Christodoulopoulos, Tanmoy Chakraborty, Carolyn Rose, and Violet Peng, editors, *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pages 20454–20486, Suzhou, China, 2025.
-  Francielle Vargas, Isabelle Carvalho, Thiago A. S. Pardo, and Fabrício Benevenuto.
Context-aware and expert data resources for brazilian portuguese hate speech detection.
Natural Language Processing, 31(2):435–456, 2024.